Analisi di un Dataset per l'Analisi sui Mercati Finanziari

Salvatore Mattiello Giuseppe Di Sarno

1 Acquisizione dei dati e costruzione del dataset

Per la realizzazione di questo studio, è stato selezionato il mercato delle criptovalute come dominio di riferimento, in particolare la coppia di trading **SOL/USDT** (Solana/Tether). La scelta di questo asset è motivata dalla sua elevata liquidità e volatilità, caratteristiche che rendono i pattern di prezzo particolarmente significativi per l'analisi tecnica.

I dati sono stati acquisiti tramite l'exchange **Binance**, una delle piattaforme di scambio più grandi e affidabili al mondo. Binance offre un accesso programmatico ai dati storici di mercato attraverso le sue **API pubbliche**, grazie alle quali riusciamo a scaricare candele con diversi intervalli di tempo e permettono il download massivo di dati storici senza costi diretti.

1.1 La candela finanziaria e le sue caratteristiche principali

Una candela sintetizza l'andamento del prezzo di un asset all'interno di un intervallo temporale prefissato (ad esempio 1 minuto, 1 ora o 1 giorno), fornendo una rappresentazione compatta ma informativa delle dinamiche di mercato.

Ogni candela è caratterizzata da quattro valori principali di prezzo: apertura (Open), massimo (High), minimo (Low) e chiusura (Close). Graficamente, la candela è composta da un corpo centrale, che rappresenta la differenza tra prezzo di apertura e di chiusura, e da due estremità chiamate ombre o shadow, che indicano i valori massimo e minimo raggiunti durante l'intervallo. Se il prezzo di chiusura è superiore a quello di apertura, la candela indica una fase di crescita del prezzo; viceversa, se il prezzo di chiusura è inferiore, la candela rappresenta una fase di ribasso.

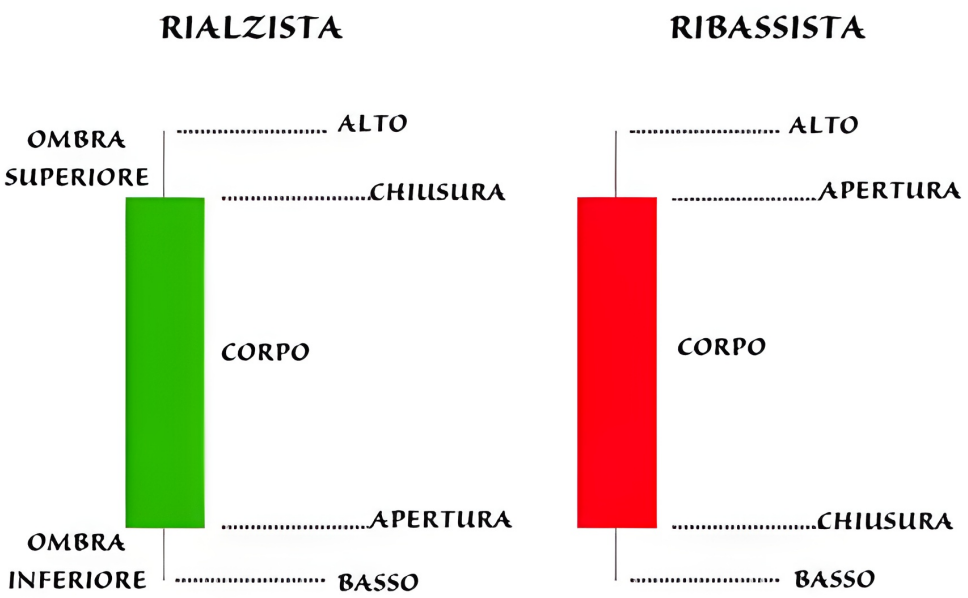


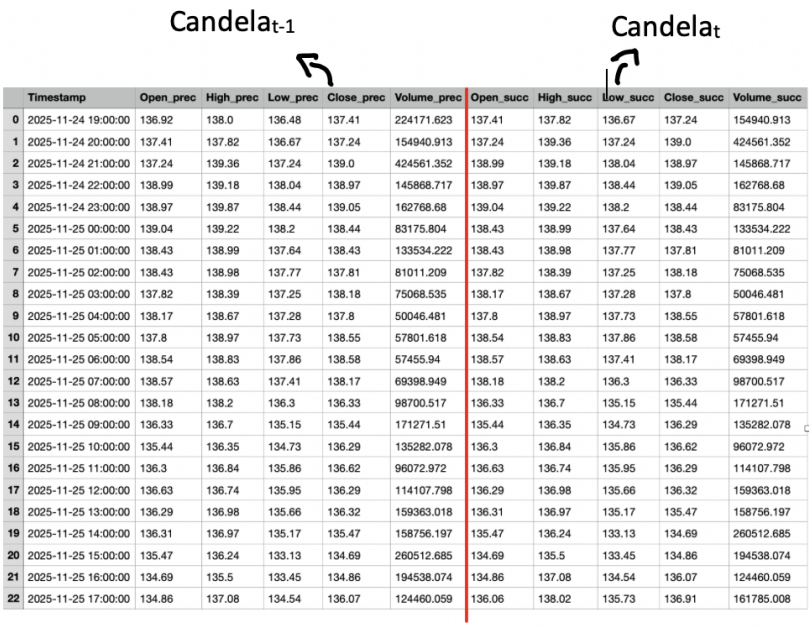
Figura 1: Struttura della candela

Le candele permettono quindi di osservare non solo il valore finale del prezzo, ma anche la sua variabilità nel tempo, rendendole uno strumento particolarmente efficace per l'individuazione di pattern ricorrenti e segnali di mercato. Per questo motivo, esse costituiscono la base informativa del dataset utilizzato in questo studio.

1.2 Struttura del dataset iniziale

Il dataset acquisito è una **serie storica finanziaria** (Time Series) relativa a un intervallo di tempo specifico, nel nostro caso 1 ora. I dati coprono il periodo compreso tra il *24 Novembre 2025* e il *7 Dicembre 2025*. La struttura del dato grezzo scaricato da Binance comprende i seguenti campi fondamentali (OHLCV):

1. **Timestamp (Open Time):** L'istante preciso di inizio della candela.
2. **Open (o):** Il prezzo dell'asset all'inizio dell'intervallo temporale.
3. **High (M):** Il prezzo più alto raggiunto durante l'intervallo.
4. **Low (m):** Il prezzo più basso toccato durante l'intervallo.
5. **Close (c):** Il prezzo dell'asset alla fine dell'intervallo temporale.
6. **Volume (V):** La quantità totale di asset scambiata durante l'intervallo.



	Timestamp	Open_prec	High_prec	Low_prec	Close_prec	Volume_prec	Open_succ	High_succ	Low_succ	Close_succ	Volume_succ
0	2025-11-24 19:00:00	136.92	138.0	136.48	137.41	224171.623	137.41	137.82	136.67	137.24	154940.913
1	2025-11-24 20:00:00	137.41	137.82	136.67	137.24	154940.913	137.24	139.36	137.24	139.0	424561.352
2	2025-11-24 21:00:00	137.24	139.36	137.24	139.0	424561.352	138.99	139.18	138.04	138.97	145868.717
3	2025-11-24 22:00:00	138.99	139.18	138.04	138.97	145868.717	138.97	139.87	138.44	139.05	162768.68
4	2025-11-24 23:00:00	138.97	139.87	138.44	139.05	162768.68	139.04	139.22	138.2	138.44	83175.804
5	2025-11-25 00:00:00	139.04	139.22	138.2	138.44	83175.804	138.43	138.99	137.64	138.43	133534.222
6	2025-11-25 01:00:00	138.43	138.99	137.64	138.43	133534.222	138.43	138.98	137.77	137.81	81011.209
7	2025-11-25 02:00:00	138.43	138.98	137.77	137.81	81011.209	137.82	138.39	137.25	138.18	75068.535
8	2025-11-25 03:00:00	137.82	138.39	137.25	138.18	75068.535	138.17	138.67	137.28	137.8	50046.481
9	2025-11-25 04:00:00	138.17	138.67	137.28	137.8	50046.481	137.8	138.97	137.73	138.55	57801.618
10	2025-11-25 05:00:00	137.8	138.97	137.73	138.55	57801.618	138.54	138.83	137.86	138.58	57455.94
11	2025-11-25 06:00:00	138.54	138.83	137.86	138.58	57455.94	138.57	138.63	137.41	138.17	69398.949
12	2025-11-25 07:00:00	138.57	138.63	137.41	138.17	69398.949	138.18	138.2	136.3	136.33	98700.517
13	2025-11-25 08:00:00	138.18	138.2	136.3	136.33	98700.517	136.33	136.7	135.15	135.44	171271.51
14	2025-11-25 09:00:00	136.33	136.7	135.15	135.44	171271.51	135.44	136.35	134.73	136.29	135282.078
15	2025-11-25 10:00:00	135.44	136.35	134.73	136.29	135282.078	136.3	136.84	135.86	136.62	96072.972
16	2025-11-25 11:00:00	136.3	136.84	135.86	136.62	96072.972	136.63	136.74	135.95	136.29	114107.798
17	2025-11-25 12:00:00	136.63	136.74	135.95	136.29	114107.798	136.29	136.98	135.66	136.32	159363.018
18	2025-11-25 13:00:00	136.29	136.98	135.66	136.32	159363.018	136.31	136.97	135.17	135.47	158756.197
19	2025-11-25 14:00:00	136.31	136.97	135.17	135.47	158756.197	135.47	136.24	133.13	134.69	260512.685
20	2025-11-25 15:00:00	135.47	136.24	133.13	134.69	260512.685	134.69	135.5	133.45	134.86	194538.074
21	2025-11-25 16:00:00	134.69	135.5	133.45	134.86	194538.074	134.86	137.08	134.54	136.07	124460.059
22	2025-11-25 17:00:00	134.86	137.08	134.54	136.07	124460.059	136.06	138.02	135.73	136.91	161785.008

Figura 2: Dataset iniziale

Il dataset di partenza non è un semplice feed OHLCV (Open, High, Low, Close, Volume), ma è una **struttura pre-concatenata** pensata per l'analisi di dipendenza seriale (causa $\rightarrow$ effetto).

Ogni singola riga del dataset (un *Record Evento*) è costruita affiancando le informazioni della candela precedente ($t-1$) a quelle della candela successiva (t).

Il dataset (es. `dataset_iniziale.csv`) presenta immediatamente il seguente schema base, necessario per stabilire la relazione di causalità:

Prefisso	**Descrizione**
`_prec`	Caratteristiche della **Candela Precedente** ($\mathbf{t-1}$), utilizzate come **variabili di input** (*Causa*).
`_succ`	Caratteristiche della **Candela Successiva** (**t**), utilizzate come **variabili target** (*Effetto*).

Inizialmente, il dataset era composto solo dalle colonne OHLCV grezze concatenate ($\text{OHLCV}_{t-1}, \text{OHLCV}_t$).

2 Obiettivo dello studio e ipotesi di ricerca

L'obiettivo principale di questo progetto è verificare l'esistenza di una relazione statistica misurabile tra le caratteristiche di una candela di prezzo e la reazione del mercato nella candela immediatamente successiva.

In particolare, lo studio si concentra sulla possibilità di sintetizzare l'informazione contenuta in una singola candela precedente ($t-1$) in una variabile numerica continua, in grado di rappresentarne l'intenzione direzionale, e di valutare se tale informazione influenzi in modo sistematico il comportamento della candela successiva (t).

Dal punto di vista statistico, il problema viene formulato come un'analisi di dipendenza tra due variabili:

- una variabile indipendente X, costruita a partire dai dati OHLCV della candela precedente;
- una variabile dipendente Y, che misura la reazione direzionale della candela successiva.

L'ipotesi nulla (H_0) assume l'assenza di una relazione significativa tra X e Y, ovvero che la configurazione della candela precedente non contenga informazione utile per spiegare la dinamica della candela successiva.

L'ipotesi alternativa (H_1) postula invece l'esistenza di una dipendenza statistica tra le due variabili, tale per cui variazioni sistematiche in X siano associate a variazioni coerenti nella distribuzione di Y.

L'analisi non ha come obiettivo la costruzione di una strategia di trading o di un modello predittivo operativo, ma si inserisce in un contesto puramente esplorativo e quantitativo, volto a valutare se e in che misura la struttura locale del prezzo possa essere associata a una risposta direzionale successiva del mercato.

3 Definizione delle variabili di studio

3.1 Costruzione della variabile esplicativa X

L'analisi richiede una rappresentazione sintetica della candela precedente ($t-1$). A tal fine, i dati OHLC vengono trasformati in una variabile continua X_{t-1}, progettata per catturare (i) la direzione del movimento, (ii) la forza relativa del corpo e (iii) la coerenza della struttura delle ombre con tale direzione.

3.1.1 Direzione della candela

Sia o_{t-1} il prezzo di apertura e c_{t-1} il prezzo di chiusura della candela precedente. La direzione viene definita come:

$$\text{dir}_{t-1} = \begin{cases} +1 & \text{se } c_{t-1} > o_{t-1} \\ -1 & \text{se } c_{t-1} < o_{t-1} \\ 0 & \text{se } c_{t-1} = o_{t-1} \end{cases}$$

3.1.2 Forza Relativa del Corpo

L'intensità del movimento viene misurata tramite l'ampiezza del corpo:

$$\text{body}_{t-1} = |c_{t-1} - o_{t-1}|$$

e normalizzata rispetto al range totale della candela:

$$\text{range}_{t-1} = M_{t-1} - m_{t-1}, \qquad \text{body_ratio}_{t-1} = \frac{\text{body}_{t-1}}{\text{range}_{t-1}}.$$

La quantità $\text{body_ratio}_{t-1} \in [0,1]$ rappresenta la quota del range occupata dal corpo e fornisce una misura adimensionale della "decisione" della candela.

3.1.3 Ombre e fattore di coerenza

Le ombre superiore e inferiore vengono definite come:

$$\text{upper}_{t-1} = M_{t-1} - \max(o_{t-1}, c_{t-1}), \qquad \text{lower}_{t-1} = \min(o_{t-1}, c_{t-1}) - m_{t-1}.$$

Per sintetizzare lo sbilanciamento tra ombre si introduce:

$$\text{shadow_bias}_{t-1} = \frac{\text{lower}_{t-1} - \text{upper}_{t-1}}{\text{range}_{t-1}}.$$

Poiché shadow_bias_{t-1} è positivo quando prevale l'ombra inferiore e negativo quando prevale l'ombra superiore, il suo contributo viene reso coerente con la direzione della candela mediante un fattore firmato:

$$\text{shadow_factor}_{t-1} = 1 + \text{dir}_{t-1} \cdot \text{shadow_bias}_{t-1}.$$

In questo modo, in caso rialzista ($\text{dir}_{t-1} = +1$) il segnale viene amplificato quando prevale l'ombra inferiore, mentre in caso ribassista ($\text{dir}_{t-1} = -1$) il segnale viene amplificato quando prevale l'ombra superiore; nel caso opposto il fattore attenua l'intensità senza invertire il segno.

3.1.4 Definizione finale della variabile X

La variabile esplicativa finale è definita come:

$$X_{t-1} = \text{dir}_{t-1} \cdot \text{body_ratio}_{t-1} \cdot \text{shadow_factor}_{t-1}.$$

Valori positivi di X indicano una pressione rialzista, valori negativi una pressione ribassista, mentre valori prossimi allo zero corrispondono a configurazioni poco informative. L'intensità di X riflette il grado di convinzione direzionale implicito nella candela precedente, misurato in termini relativi e adimensionali.

3.2 Definizione della variabile di risposta Y

Una volta definita la variabile esplicativa X, è necessario individuare una misura quantitativa che rappresenti in modo coerente la reazione del mercato nella candela successiva. Tale misura costituisce la variabile di risposta Y.

L'obiettivo della costruzione di Y è quantificare l'ampiezza e la direzione dell'impulso di prezzo che segue la configurazione osservata al tempo $t-1$, evitando misure eccessivamente rumorose o dipendenti dalla scala dei prezzi.

3.2.1 Motivazione della scelta

Una misura basata esclusivamente sulla variazione tra i prezzi di chiusura ($c_t - c_{t-1}$) risulta insufficiente per catturare la dinamica intraperiodale del mercato, in quanto ignora le escursioni estreme che possono verificarsi all'interno dell'intervallo temporale.

Per questo motivo, la reazione viene definita in termini di estensione massima del prezzo nella direzione suggerita dalla candela precedente, misurata a partire dal prezzo di chiusura al tempo $t-1$.

3.2.2 Impulso direzionale

Sia dir_{t-1} la direzione della candela precedente, definita come nel capitolo precedente. La reazione direzionale della candela successiva viene misurata come:

$$\Delta_t = \begin{cases} M_t - c_{t-1} & \text{se } \text{dir}_{t-1} = +1 \\ m_t - c_{t-1} & \text{se } \text{dir}_{t-1} = -1 \\ 0 & \text{se } \text{dir}_{t-1} = 0 \end{cases}$$

dove M_t e m_t rappresentano rispettivamente il massimo e il minimo della candela successiva.

Questa definizione consente di misurare l'estensione massima del prezzo nella direzione associata alla configurazione della candela precedente.

3.2.3 Normalizzazione della reazione

Per rendere la misura confrontabile nel tempo e indipendente dalla volatilità del mercato, l'impulso direzionale viene normalizzato rispetto al range della candela precedente:

$$\text{range}_{t-1} = M_{t-1} - m_{t-1}$$

La variabile di risposta viene quindi definita come:

$$Y_t = \frac{\Delta_t}{\text{range}_{t-1}}$$

Questa normalizzazione consente di interpretare Y come una misura relativa dell'intensità della reazione, espressa in unità di "candela precedente".

3.3 Coerenza del segno e interpretazione

Con la definizione adottata, il segno della variabile Y_t indica la direzione assoluta della reazione del mercato nella candela successiva:

- $Y_t > 0$ indica un'estensione del prezzo verso l'alto;
- $Y_t < 0$ indica un'estensione del prezzo verso il basso;
- $Y_t \approx 0$ indica l'assenza di una reazione direzionale significativa.

L'intensità dell'impulso è catturata dal valore assoluto $|Y_t|$, che misura la potenza relativa del movimento in unità del range della candela precedente. La variabile Y fornisce quindi una misura continua e firmata della risposta del mercato, senza incorporare direttamente un giudizio di successo o fallimento del segnale direzionale precedente.

3.4 Integrazione delle feature nel dataset finale

Le trasformazioni introdotte nei paragrafi precedenti non sono utilizzate unicamente per la costruzione delle variabili aggregate X_{t-1} e Y_t, ma vengono anche incluse nel dataset finale come feature distinte. A partire dai dati OHLCV originali, il dataset viene arricchito con grandezze derivate che descrivono la struttura della candela precedente, includendo direzione, ampiezza del corpo normalizzata, caratteristiche delle ombre, bias direzionale, peso strutturale e volume relativo.

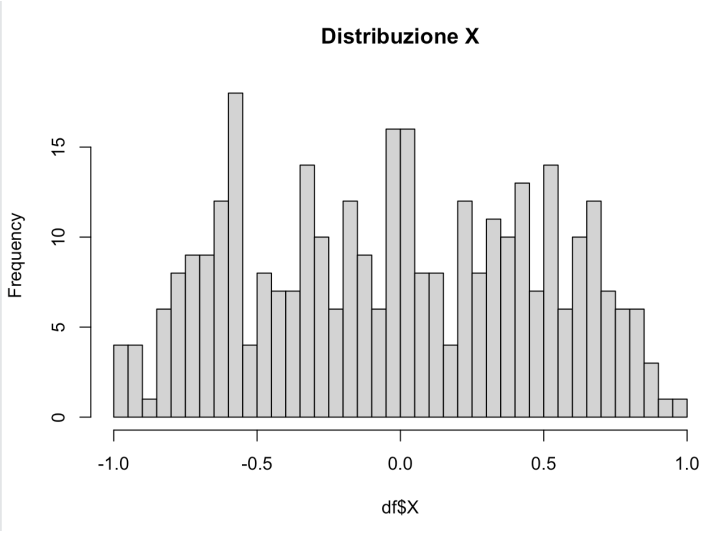
Il dataset finale risulta quindi composto da:

- dati di base (OHLCV),
- feature strutturali della candela precedente, che descrivono in modo disaggregato la configurazione geometrica e volumetrica,
- variabile esplicativa sintetica X_{t-1}, che integra tali informazioni in un'unica misura continua,
- variabile di risposta Y_t, che quantifica la reazione del mercato nella candela successiva.

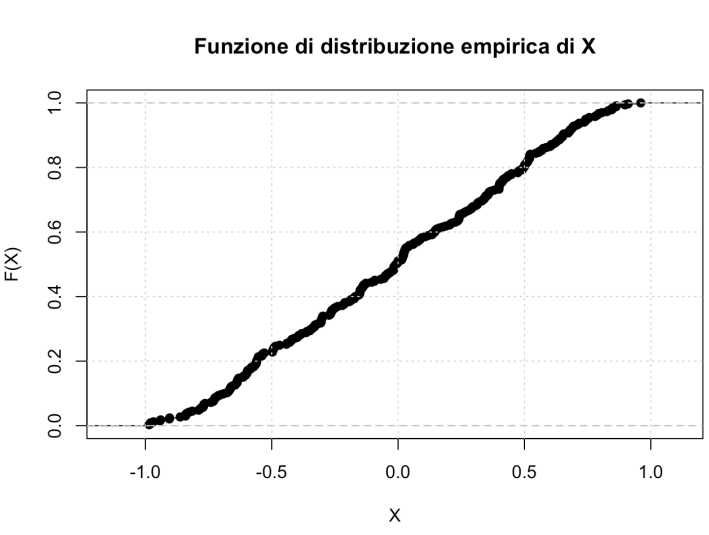
4 Analisi esplorativa e relazione tra X e Y

4.1 Analisi descrittiva della variabile X

L'istogramma della variabile X mostra una distribuzione continua approssimativamente simmetrica, che si estende lungo l'intero intervallo $[-1, 1]$ con frequenze relativamente omogenee, comprese tra 5 e 15 osservazioni per classe. A differenza di quanto ci si potrebbe aspettare da una variabile puramente di indecisione, non si osserva un picco netto attorno allo zero: il mercato produce con frequenza comparabile sia configurazioni di neutralità che episodi di pressione direzionale più marcata, distribuiti in modo abbastanza uniforme lungo l'intero dominio della variabile.



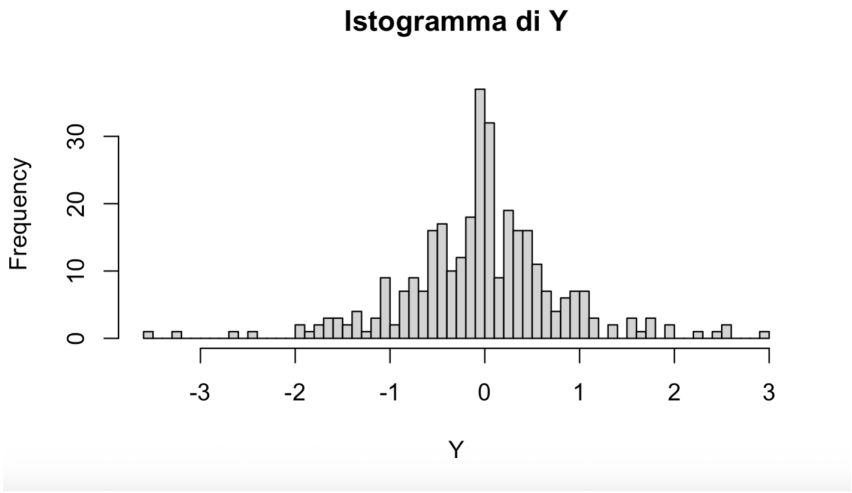
La funzione di distribuzione empirica continua (ECDF) di X mostra una crescita sostanzialmente regolare lungo l'intero intervallo $[-1, 1]$, coerente con la distribuzione omogenea evidenziata dall'istogramma. L'assenza di salti bruschi o tratti particolarmente ripidi conferma che le osservazioni sono distribuite in modo abbastanza uniforme lungo il dominio della variabile, senza concentrazioni marcate attorno a valori specifici.



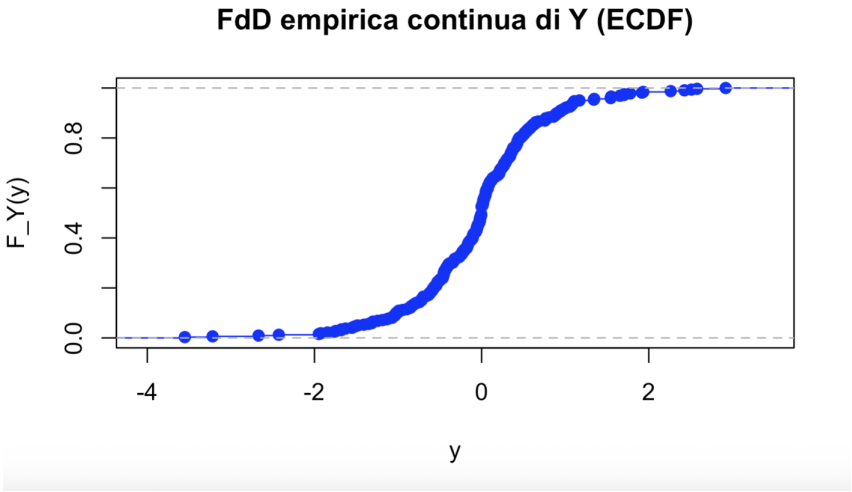
4.2 Analisi descrittiva della variabile Y

L'analisi descrittiva della variabile di risposta Y evidenzia un comportamento sensibilmente diverso rispetto a quello di X. L'istogramma mostra una distribuzione più dispersa, caratterizzata da code più estese e da una maggiore variabilità complessiva. Questo risultato riflette la natura intrinsecamente rumorosa della reazione del mercato, che può manifestarsi con intensità molto diverse anche in presenza di segnali iniziali simili.

Dal punto di vista economico, ciò suggerisce che la risposta del mercato non dipende esclusivamente dalla struttura della candela precedente, ma è influenzata da numerosi fattori esogeni e non osservabili, come nuove informazioni, variazioni improvvise della liquidità o dinamiche di breve periodo.



La funzione di distribuzione empirica continua di Y cresce in modo più graduale rispetto a quella di X, indicando una dispersione più elevata delle osservazioni lungo l'intervallo dei valori possibili. Questo andamento conferma che la variabile di risposta presenta una variabilità intrinseca maggiore rispetto al segnale sintetico che la precede, rendendo il problema di previsione particolarmente complesso.

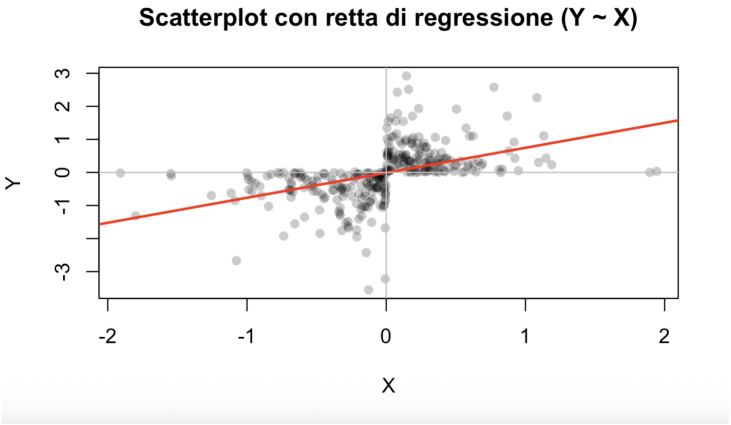


4.3 Analisi bivariata

Lo scatterplot tra X e Y fornisce una prima evidenza visiva della relazione tra le due variabili. Nel complesso emerge una tendenza positiva: valori più elevati di X, che rappresentano una maggiore pressione direzionale implicita nella candela precedente, sono associati in media a valori più elevati di Y, ossia a una reazione di prezzo più intensa nella stessa direzione.

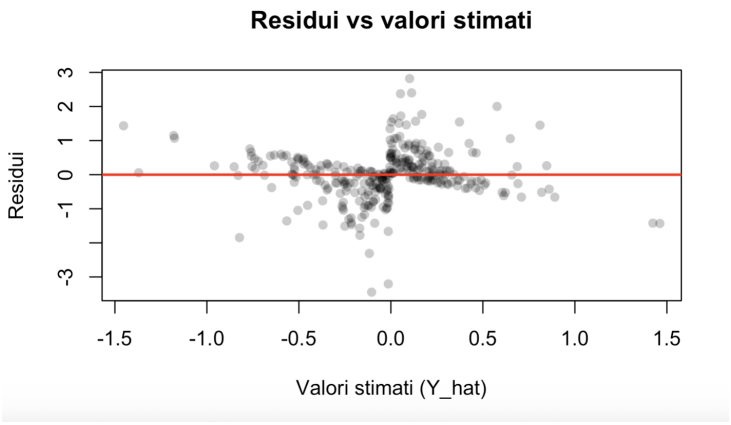
Tuttavia, tale relazione è accompagnata da una marcata dispersione dei punti, che segnala una variabilità elevata della risposta del mercato. Questo comportamento è coerente con l'idea che la variabile X catturi una componente informativa reale, ma non sufficiente a spiegare da sola l'intera dinamica della variabile di risposta.

La retta di regressione lineare sovrapposta allo scatterplot consente di visualizzare la tendenza media della relazione, evidenziando l'esistenza di una dipendenza positiva complessiva, pur in presenza di un'elevata incertezza individuale sulle singole osservazioni.



4.4 Diagnostica: residui vs valori stimati

Il grafico dei residui rispetto ai valori stimati risulta complessivamente centrato intorno allo zero, ma con dispersione non costante lungo l'intervallo dei valori stimati, evidenziando eteroschedasticità.



5 Clustering delle strutture di candela

5.1 Obiettivo e motivazione

L'obiettivo di questa analisi è stato quello di individuare strutture omogenee all'interno del dataset, classificando ciascuna candela sulla base delle sue caratteristiche intrinsiche. In una prima fase esplorativa, l'obiettivo era clusterizzare su relazioni tipo X-Y per individuare delle strutture ricorrenti nel mercato. La scelta di adottare un'altro approccio nasce da due motivi principali:

1. **Scarsa interpretabilità** Anche quando il clustering produceva dei gruppi, non era chiaro cosa rappresentassero dal punto di vista finanziario. I cluster risultavano difficili da collegare a comportamenti riconoscibili del mercato.

2. **Coerenza con l'obiettivo del clustering** Lo scopo del clustering, non è prevedere né modellare una dinamica temporale, ma scoprire strutture omogenee nei dati.

Per questo si è deciso di ricondurre il problema a una descrizione intrinseca della singola candela, rendendo ogni osservazione autosufficiente e direttamente interpretabile.
La scelta di clusterizzare la struttura interna della candela risponde a una logica precisa:

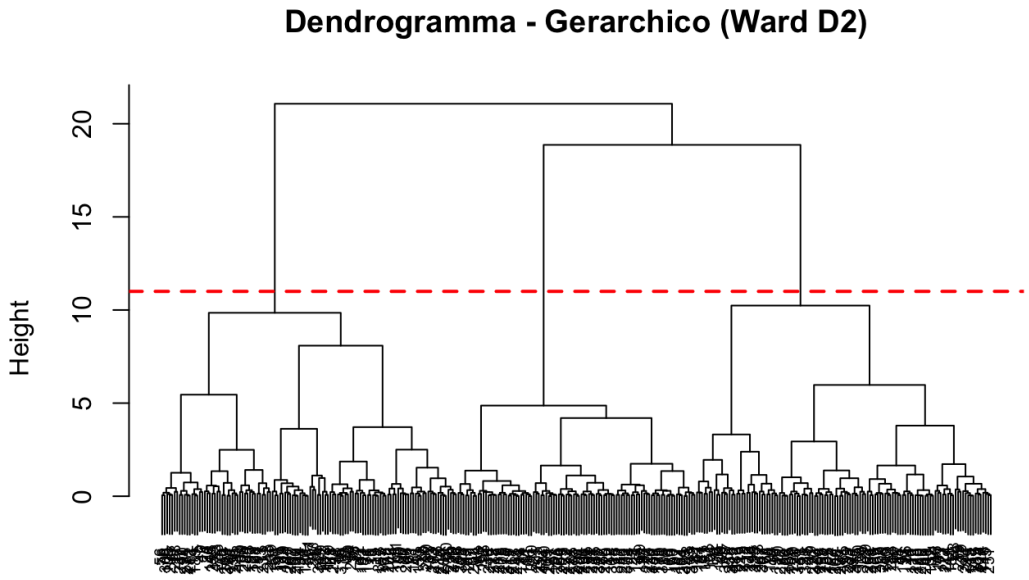
- la candela è l'unità informativa fondamentale nei mercati finanziari;
- la sua forma sintetizza in modo compatto il confronto tra forza di acquista e vendita in un determinato intervallo temporale
- candele con forma simile riflettono configurazioni di mercato simili, indipendentemente dal livello assoluto dei prezzi

In particolare, la matrice dei dati è stata costruita includendo indicatori che descrivono la proporzione del corpo rispetto al range totale, lo sbilanciamento tra ombre superiore e inferiore, la rilevanza relativa delle ombre, l'ampiezza del movimento e l'intensità dell'attività di mercato, opportunamente trasformati per ridurre l'influenza di valori estremi. Questa scelta consente di rappresentare ciascuna candela come un punto in uno spazio multidimensionale, nel quale la distanza tra punti riflette la similarità strutturale tra candele.

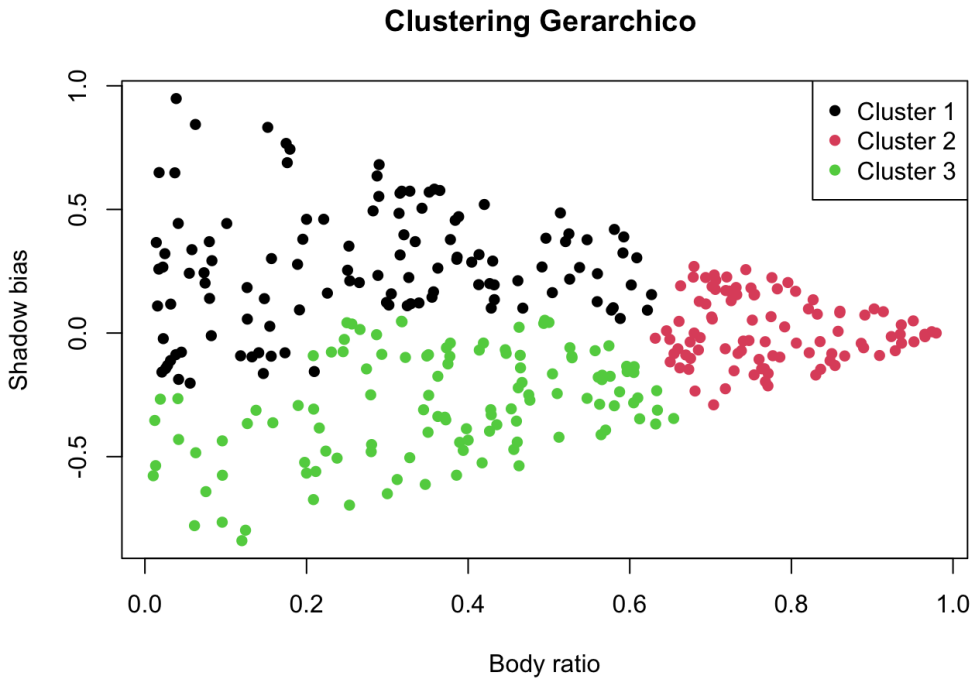
Poiché le variabili considerate presentano scale e ordini di grandezza differenti, è stata applicata una standardizzazione preliminare, così da rendere la distanza euclidea una misura coerente della dissimilarità complessiva. Questo passaggio è fondamentale per evitare che singole variabili dominino il processo di clustering esclusivamente per effetto della loro scala numerica.

5.2 Clustering gerarchico esplorativo

La fase successiva ha previsto l'applicazione di un clustering gerarchico agglomerativo, utilizzato con finalità esplorative. Attraverso la costruzione del dendrogramma e l'analisi delle altezze di fusione, è stato possibile osservare la struttura globale dei dati e individuare intervalli nei quali le aggregazioni avvengono a distanze significativamente maggiori.

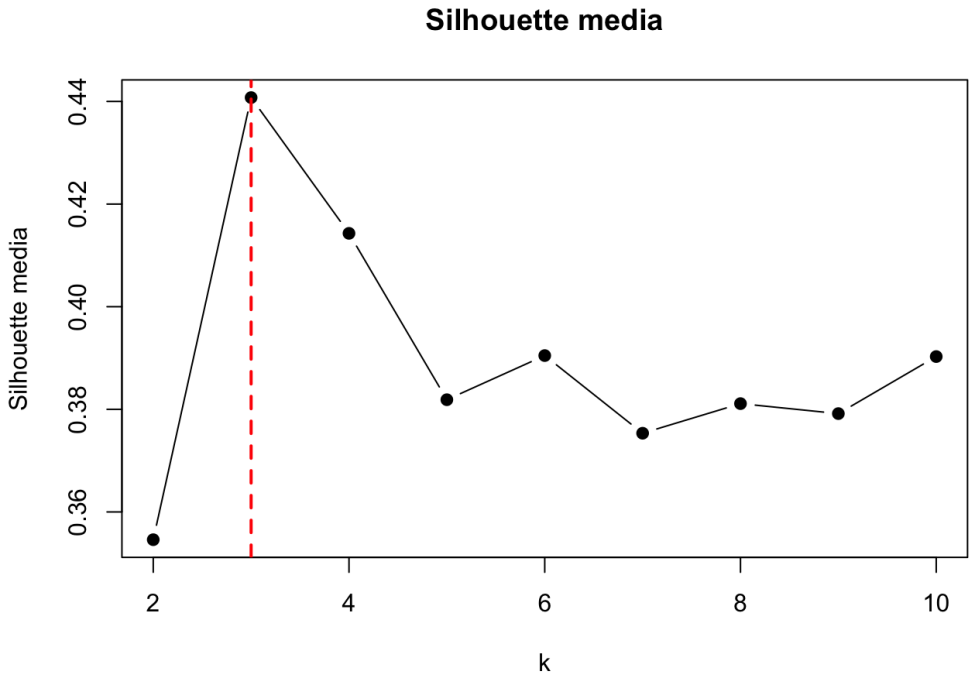


In questo contesto è stato adottato il criterio di **Ward D2**, che minimizza la varianza interna ai cluster ad ogni passo di aggregazione, producendo gruppi compatti e ben separati. Tale criterio risulta particolarmente adatto quando l'obiettivo è ottenere una struttura gerarchica leggibile e una scelta motivata del numero di cluster.



5.3 Scelta del numero di cluster (silhouette)

La scelta del numero di cluster non è stata effettuata a priori, ma è stata guidata da criteri empirici di valutazione della qualità della partizione. In particolare, oltre all'osservazione del dendrogramma, è stata calcolata la silhouette media per diversi valori del numero di cluster. La silhouette consente di valutare simultaneamente la compattezza interna dei cluster e la loro separazione reciproca, fornendo una misura sintetica della bontà del clustering. Il valore massimo della silhouette media è stato ottenuto per tre cluster, suggerendo che tale partizione rappresenta il miglior compromesso tra omogeneità interna e separazione tra gruppi.

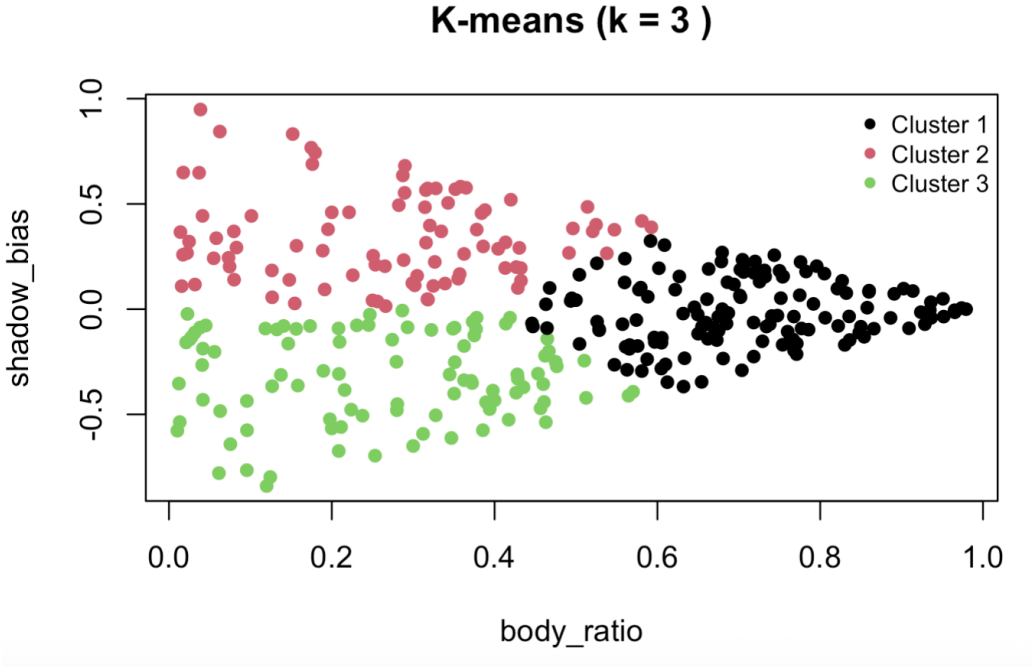


5.4 *K*-means e partizione finale

Una volta determinato il numero di cluster ottimale, è stato applicato il metodo non gerarchico del *k-means*, con $k = 3$, al fine di ottenere una partizione finale stabile.

Il *k-means* consente di minimizzare la dispersione interna ai cluster, riallocando iterativamente le osservazioni al centroide più vicino fino al raggiungimento di una configurazione di equilibrio. Tale procedura è coerente con la funzione obiettivo del clustering, che mira a minimizzare la non omogeneità interna dei gruppi e, indirettamente, a massimizzare la separazione tra i cluster stessi.

L'analisi descrittiva dei cluster ottenuti ha permesso di attribuire a ciascun gruppo un'interpretazione finanziaria chiara e coerente.



5.5 Interpretazione dei cluster

Sebbene entrambi i metodi individuino strutture coerenti nel dataset, emergono differenze nella composizione dei gruppi, dovute alla diversa natura dei due approcci.

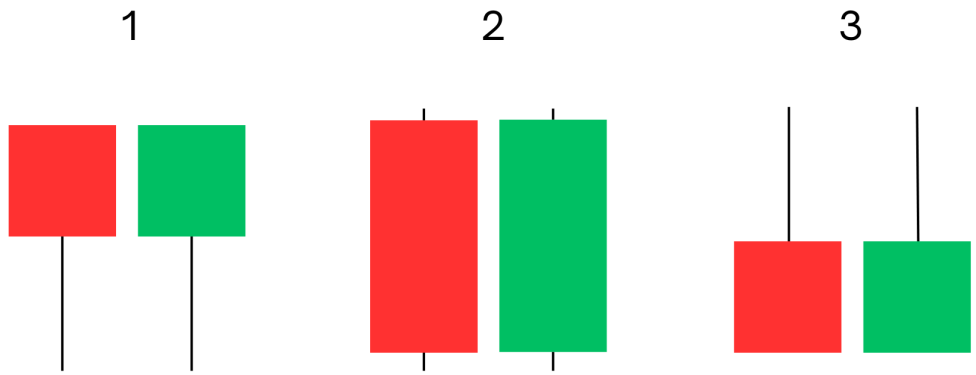
Il clustering gerarchico, utilizzato in questa analisi con finalità esplorative, consente di osservare l'intera struttura delle aggregazioni senza imporre a priori il numero di cluster, ma non permette la riallocazione delle osservazioni una volta effettuate le fusioni. Il metodo *k*-means, al contrario, riassegna iterativamente le osservazioni ai centroidi più vicini, producendo una partizione finale più stabile e maggiormente orientata alla minimizzazione della dispersione interna ai cluster. Per tali motivi, il *k*-means è stato adottato come metodo finale di classificazione delle candele.

In particolare:

- il **Cluster 2** risulta caratterizzato da candele con un corpo ampio rispetto al range totale (body_ratio medio pari a 0.707) e shadow_bias prossimo allo zero, indicando ombre bilanciate e movimento direzionale netto. Tali caratteristiche configurano un insieme di **candele direzionali o impulsive**, tipicamente associate a fasi di mercato in cui la pressione di acquisto o vendita è ben definita e sostenuta.

- il **Cluster 1** presenta corpi più contenuti (body_ratio medio pari a 0.273) e uno shadow_bias positivo (0.338), indicando una prevalenza dell'ombra inferiore. Questo suggerisce situazioni in cui il prezzo testa livelli più bassi ma viene respinto verso l'alto, configurazione tipica di **pressione di acquisto** o prossimità a livelli di supporto.

- il **Cluster 3** presenta anch'esso corpi contenuti (body_ratio medio pari a 0.261) ma con shadow_bias negativo (-0.322), indicando una prevalenza dell'ombra superiore. Questo riflette situazioni di **rifiuto rialzista**, in cui il prezzo tenta un movimento verso l'alto ma viene respinto, tipicamente osservabile in prossimità di livelli di resistenza.

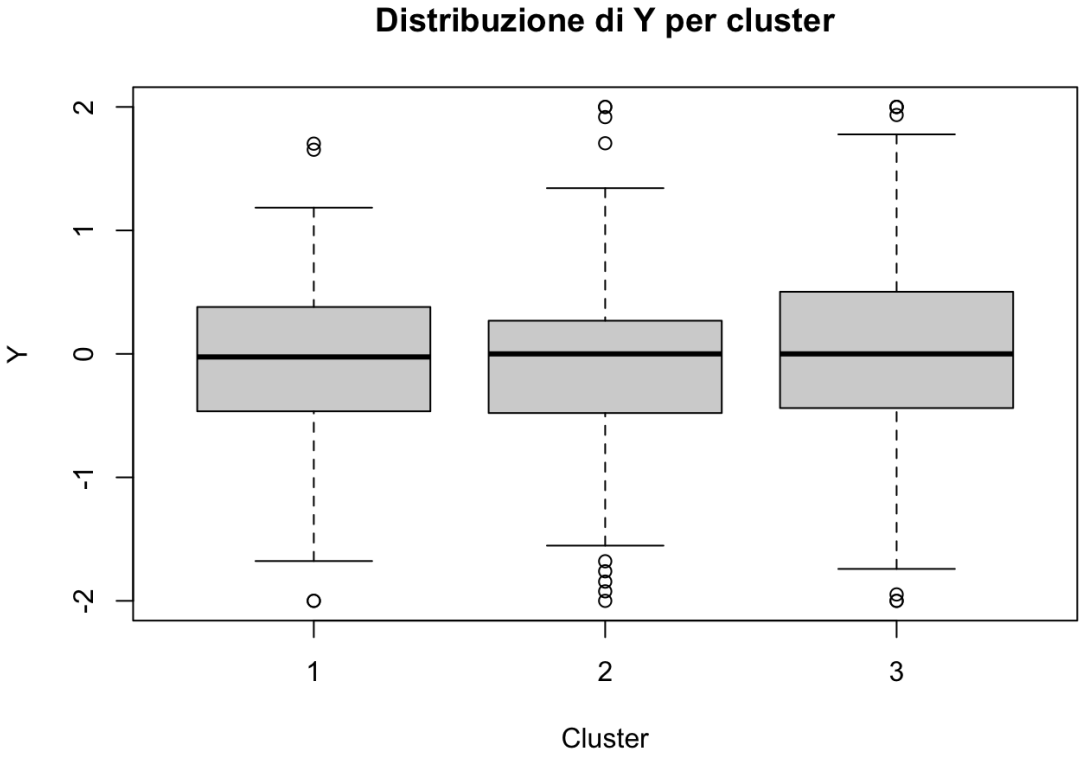


5.6 Validazione a posteriori tramite Y

Dall'analisi della distribuzione della variabile Y per cluster emergono tre regimi di risposta del mercato, coerenti con le caratteristiche strutturali di ciascun gruppo.

Il **Cluster 2** (*body_ratio* $= 0.707$, candele impulsive) mostra una distribuzione di Y con dispersione elevata ($sd_Y = 0.719$) e outlier significativi in entrambe le direzioni, riflettendo un effetto di **momentum**: il mercato tende a prolungare il movimento nella direzione della candela precedente, indipendentemente dal suo verso.

Il **Cluster 1** (*shadow_bias* $= +0.338$) e il **Cluster 3** (*shadow_bias* $= -0.322$) presentano invece medie di Y prossime allo zero quando considerati nella loro interezza. Questo risultato è attribuibile alla coesistenza di candele rialziste e ribassiste all'interno di ciascun gruppo, le cui reazioni si compensano reciprocamente. Come approfondito nella sezione successiva, la risposta direzionale di Y emerge chiaramente solo una volta condizionata alla direzione della singola candela.




```
=== Tabella di profilo dei cluster (K-means) ===
# A tibble: 3 × 5
  cluster_km     n body_ratio shadow_bias  mean_Y
  <fct>      <int>      <dbl>       <dbl>   <dbl>
1 1             93      0.273       0.338  -0.0683
2 2            140      0.707      -0.0145 -0.0576
3 3             98      0.261      -0.322   0.0548
```

6 Analisi Condizionale: Direzione e Struttura della Candela

6.1 Motivazione e quesito

L'analisi della distribuzione di Y per cluster, condotta nella sezione precedente, ha evidenziato che i tre cluster presentano medie di Y prossime allo zero quando considerati nella loro interezza. Questo risultato, apparentemente deludente, nasconde una fonte di eterogeneità interna: all'interno di ciascun cluster coesistono candele rialziste e ribassiste, le cui reazioni successive si compensano reciprocamente nella media aggregata.

Si pone quindi il seguente quesito di ricerca: **la direzione della candela, combinata con la struttura geometrica del cluster di appartenenza, produce una risposta di Y sistematicamente più intensa rispetto al caso opposto?**

6.2 Metodologia di filtraggio

Per rispondere al quesito, ciascun cluster è stato suddiviso in due sottogruppi in base alla direzione della candela:

- **Cluster 1** (*shadow_bias* positivo, ombra inferiore prevalente): candele rialziste ($dir = +1$), considerate coerenti con la struttura del cluster, e candele ribassiste ($dir = -1$), considerate incoerenti.
- **Cluster 3** (*shadow_bias* negativo, ombra superiore prevalente): candele ribassiste ($dir = -1$), considerate coerenti, e candele rialziste ($dir = +1$), considerate incoerenti.
- **Cluster 2** (candele impulsive, *body_ratio* elevato): suddiviso in rialziste e ribassiste, senza attribuire un giudizio di coerenza, in quanto la struttura impulsiva non implica una direzione privilegiata a priori.

6.3 Risultati

I risultati del filtraggio per tutti e tre i cluster sono riportati nella Tabella 2.

Tabella 2: Statistiche di Y per cluster e direzione della candela.

Cluster	Sottogruppo	mean_Y	sd_Y	n
1	Rialziste (coerente)	$+0.510$	0.412	44
1	Ribassiste (incoerente)	-0.587	0.524	49
3	Ribassiste (coerente)	-0.608	0.568	48
3	Rialziste (incoerente)	$+0.691$	0.612	50
2	Rialziste	$+0.450$	0.499	69
2	Ribassiste	-0.551	0.531	71

6.4 Interpretazione

La prima evidenza che emerge con chiarezza è che **la direzione della candela è il principale driver della variabile** Y in tutti e tre i cluster. Indipendentemente dalla struttura geometrica di appartenenza, le candele rialziste producono in media una reazione positiva e le ribassiste una reazione negativa, con una separazione netta e simmetrica in ogni gruppo.

Questo risultato porta a una conclusione importante: **il clustering strutturale non aggiunge potere predittivo su** Y **oltre quello già contenuto nella direzione**. La struttura delle ombre, pur essendo geometricamente distintiva tra i cluster, non amplifica né attenua la risposta media in modo sistematico e consistente.

6.5 Confronto tra cluster: medie e code

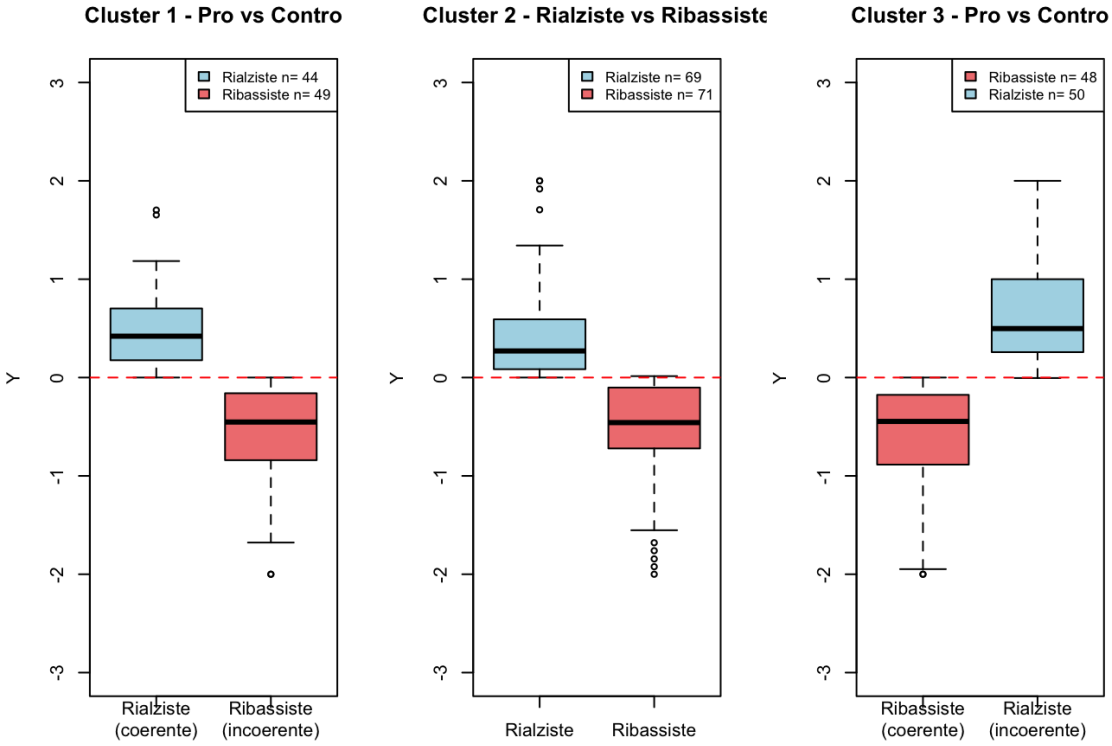
Nonostante le medie risultino simili tra i cluster, un'analisi più attenta rivela differenze rilevanti. Confrontando le **candele rialziste** tra i tre cluster:

- Cluster 1 (coerente): $\overline{Y} = +0.510$
- Cluster 2 (impulsivo): $\overline{Y} = +0.450$
- Cluster 3 (incoerente): $\overline{Y} = +0.691$

E le **candele ribassiste**:

- Cluster 1 (incoerente): $\overline{Y} = -0.587$
- Cluster 2 (impulsivo): $\overline{Y} = -0.551$
- Cluster 3 (coerente): $\overline{Y} = -0.608$

Le differenze tra medie sono contenute e non configurano un effetto sistematico attribuibile alla struttura del cluster. Tuttavia, l'analisi dei boxplot evidenzia un aspetto rilevante: **le reazioni più intense, rappresentate dagli outlier, si concentrano prevalentemente nel Cluster 2 e nei sottogruppi in cui direzione e struttura della candela sono allineate**. Questo suggerisce che, pur non modificando la media in modo drastico, la coerenza strutturale tende ad essere associata agli episodi di reazione più marcata.



6.6 Limiti e prospettive

I risultati di questa analisi condizionale portano a una conclusione di rilievo per l'interpretazione complessiva dello studio: **la struttura geometrica della singola candela, da sola, non è sufficiente come segnale operativo**.

La direzione rimane il predittore dominante, mentre la forma della candela e la coerenza con le ombre non introducono un effetto amplificatore sistematico misurabile sulla risposta media. Questo non implica che l'informazione strutturale sia priva di valore, ma che essa necessita di essere **contestualizzata** per esprimere il suo potenziale informativo.

In particolare, i risultati suggeriscono che un'analisi più completa dovrebbe integrare:

- la **fase di mercato** in cui la candela si inserisce, distinguendo contesti di trend, lateralità o indecisione, in quanto la risposta di Y è verosimilmente condizionata dal regime di mercato circostante;
- l'**analisi dei volumi**, che può fornire una misura indipendente della forza dietro il movimento direzionale, rafforzando o indebolendo il segnale implicito nella struttura della candela;
- una **finestra temporale più ampia**, che consenta di valutare se la configurazione osservata si inserisce in un contesto di continuazione o di inversione del movimento precedente.

In sintesi, la candela rappresenta un'unità informativa necessaria ma non sufficiente: il suo contributo predittivo emerge pienamente solo quando integrato in un quadro analitico più ampio, capace di catturare la dinamica complessiva del mercato.

7 Validazione del metodo su mercati differenti

Al fine di valutare la generalizzabilità del metodo proposto, l'intera pipeline di analisi è stata replicata su mercati differenti rispetto al caso di studio iniziale, includendo **mercati azionari**, **indici** e **Forex**. Per garantire coerenza e riproducibilità, i dataset sono stati scaricati tramite **Yahoo Finance**, che fornisce serie storiche omogenee per strumenti appartenenti a classi di asset diverse.

L'obiettivo di questa fase non è confrontare le performance tra mercati, bensì verificare se:

- la relazione media tra **intenzione direzionale** X e **reazione** Y persista al variare del contesto;
- le **strutture geometriche della candela** risultino stabili e quindi clusterizzabili in modo interpretabile.

7.1 Preprocessing dei dati Forex

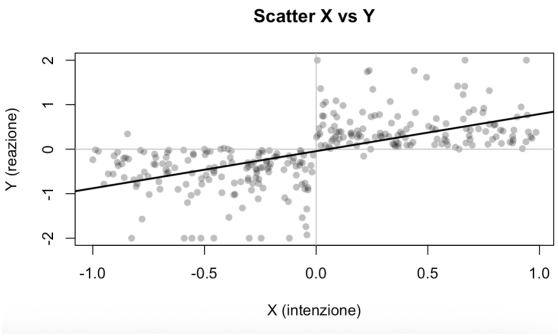
Nel mercato valutario, i valori di prezzo (in particolare per le coppie quotate contro USD) hanno un ordine di grandezza molto ridotto rispetto a quello tipico dei mercati azionari o delle criptovalute. Per evitare problemi numerici e rendere comparabili le grandezze derivate, i dataset Forex sono stati sottoposti a una trasformazione preliminare (conversione in unità assimilabili ai *pips*) tramite uno script dedicato (`trattamento_forex.R`). Questa trasformazione ha lo scopo di **normalizzare la scala**, senza alterare la struttura relativa delle candele (rapporti tra Open, High, Low e Close), e quindi senza modificare l'informazione informativa utilizzata nella costruzione di X e Y.

7.2 Risultati sui mercati analizzati

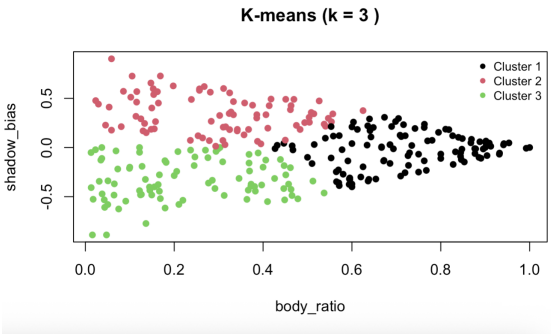
Per ogni mercato, vengono riportati congiuntamente:

- lo scatterplot tra X e Y, per osservare la relazione media tra intenzione e reazione;
- la partizione ottenuta dal *k-means* nello spazio delle feature strutturali *body ratio* e *shadow bias*, per verificare la presenza di configurazioni geometriche ricorrenti.

7.2.1 Mercato azionario (AAPL)



(a) Relazione tra X e Y

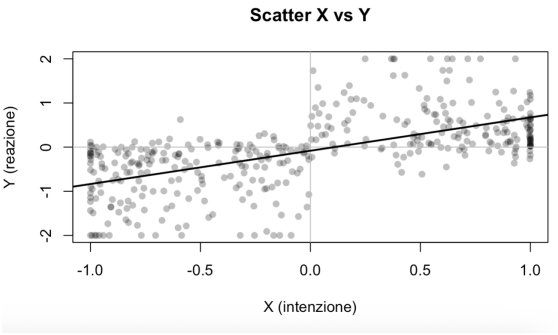


(b) Clustering su *body ratio* e *shadow bias*

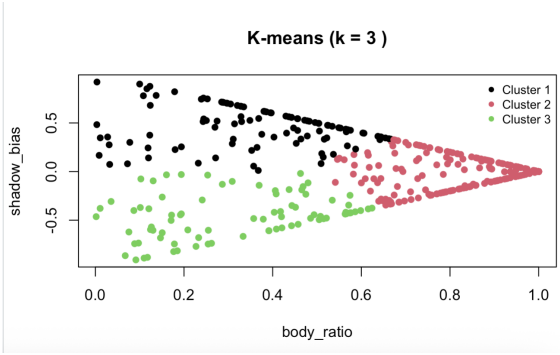
Figura 3: Risultati sul mercato azionario (AAPL).

Nel caso azionario, la relazione X–Y mostra una tendenza complessivamente positiva: a valori più elevati dell'intenzione direzionale corrispondono, in media, reazioni più coerenti nella stessa direzione. Il clustering evidenzia inoltre gruppi ben separati nello spazio strutturale delle candele, suggerendo che la geometria della candela costituisca un'informazione stabile e interpretabile anche in contesti non crypto.

7.2.2 Indice azionario (NASDAQ)



(a) Relazione tra X e Y

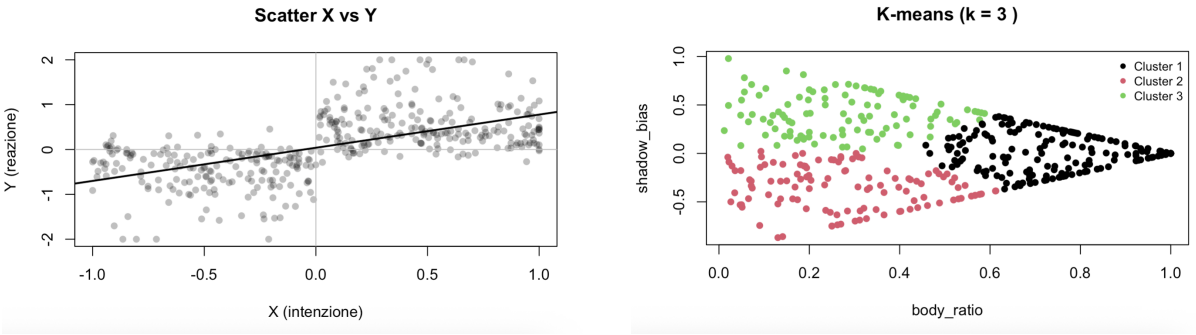


(b) Clustering su *body ratio* e *shadow bias*

Figura 4: Risultati sull'indice azionario (NASDAQ).

Nel caso degli indici, la presenza di una tendenza positiva tra X e Y rimane visibile, pur con dispersione elevata dovuta alla natura rumorosa della risposta di mercato. Anche in questo contesto, il clustering produce gruppi interpretabili e coerenti, confermando la robustezza delle feature strutturali rispetto al tipo di strumento analizzato.

7.2.3 Forex (GBP/USD)

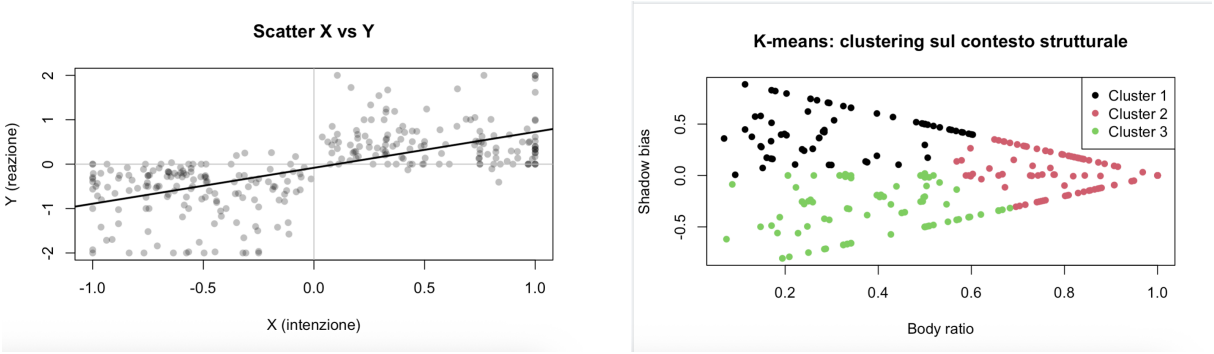


(a) Relazione tra X e Y (b) Clustering su *body ratio* e *shadow bias*

Figura 5: Risultati sul mercato Forex (GBP/USD).

Nel mercato Forex, la dispersione della variabile Y risulta generalmente più marcata, coerentemente con l'elevata liquidità e con la forte componente di rumore tipica delle dinamiche valutarie. Nonostante ciò, la relazione media tra intenzione e reazione permane, e la struttura delle candele risulta nuovamente clusterizzabile in modo chiaro e consistente.

7.2.4 Forex (EUR/USD)



(a) Relazione tra X e Y (b) Clustering su *body ratio* e *shadow bias*

Figura 6: Risultati sul mercato Forex (EUR/USD).

Anche per EUR/USD si osserva una tendenza positiva complessiva nella relazione X–Y, a conferma del fatto che la variabile X cattura una componente informativa non specifica di un singolo cross valutario. Il clustering nello spazio *body ratio–shadow bias* mostra una geometria stabile e una separazione coerente tra gruppi, rafforzando ulteriormente l'idea che la forma della candela rappresenti una proprietà trasversale del processo di formazione del prezzo.

7.3 Discussione sulla generalizzabilità

Considerando congiuntamente i risultati ottenuti sui diversi mercati, emergono due evidenze robuste:

1. la relazione media tra X e Y rimane osservabile al variare del contesto, pur in presenza di rumore elevato;

2. la struttura geometrica delle candele, descritta da *body ratio* e *shadow bias*, genera cluster interpretabili e ricorrenti anche su mercati con microstruttura differente.

In sintesi, pur non configurandosi come un modello predittivo operativo, il metodo proposto risulta **generalizzabile** come strumento di analisi esplorativa, in quanto basato su proprietà strutturali che si ripresentano in maniera coerente in classi di mercato differenti.

8 Validazione dei Dati Sintetici Generati da LLM

8.1 Obiettivo della validazione

L'obiettivo di questa fase è verificare se i dati finanziari generati sinteticamente tramite un *Large Language Model* (LLM) siano in grado di replicare le proprietà statistiche e le dinamiche comportamentali osservate nei dati reali di mercato. Tale analisi è fondamentale per determinare se i dati sintetici possano rappresentare un'alternativa valida per attività di testing, backtesting o simulazione in scenari di scarsità di dati o per la protezione della privacy.

8.2 Metodologia di generazione

8.2.1 Prompt Engineering

La generazione dei dati è stata guidata da una strategia di *Prompt Engineering* strutturata per imporre al modello vincoli di realismo finanziario e coerenza strutturale. Il prompt è stato configurato per richiedere esplicitamente:

- **Vincoli geometrici OHLC:** Rispetto rigoroso della gerarchia dei prezzi, dove $High \geq \max(Open, Close)$ e $Low \leq \min(Open, Close)$.
- **Continuità della serie storica:** Coerenza temporale tra osservazioni successive, imponendo che il prezzo di apertura della candela successiva sia identico al prezzo di chiusura della precedente ($Close_{t-1} = Open_t$).
- **Struttura Record-Evento:** Output formattato in formato CSV affiancato per facilitare l'analisi di dipendenza seriale tra la candela precedente (input) e la successiva (target).

  Prompt di Generazione Utilizzato:
  "Sei un generatore di dati finanziari di mercato realistici. Il tuo compito è creare dataset che rispettino le caratteristiche statistiche e i comportamenti tipici dei mercati finanziari reali..."

8.2.2 Configurazione del Modello e Parametri di Generazione

Per la produzione del dataset sintetico sono stati adottati i seguenti parametri tecnici:

- **Modello LLM:** Claude Sonnet 4.5.
- **Data di generazione:** Febbraio 2026.
- **Asset di riferimento:** BTC/USDT.
- **Timeframe:** 1 ora (1h).
- **Dimensione del campione:** 50 record evento (coppie di candele).

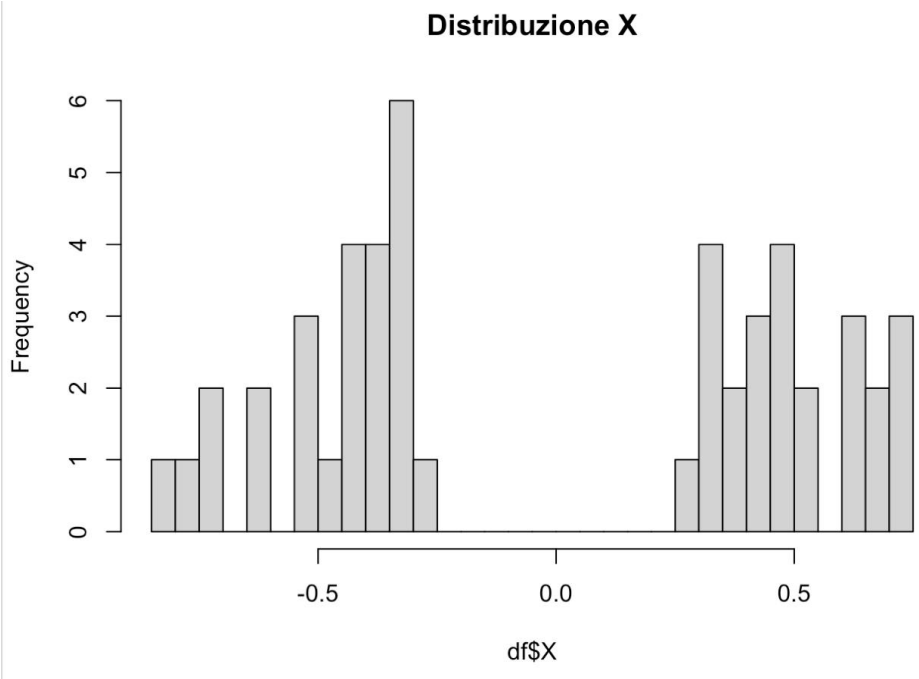
8.3 Analisi Comparativa: Dati Reali vs Dati Sintetici

In questa sezione si analizzano le somiglianze e le divergenze tra il dataset reale (SOL/USDT) e quello generato dal modello Claude Sonnet 4.5, focalizzandosi sulla capacità del LLM di replicare la microstruttura del mercato.

8.3.1 Confronto delle Distribuzioni (Variabile X)

L'analisi descrittiva condotta sui dati reali ha mostrato una variabile esplicativa X fortemente concentrata attorno allo zero, con una distribuzione approssimativamente simmetrica che riflette l'indecisione tipica del mercato.

- **Dati Reali:** Presentano code pesanti (*fat tails*) e rari valori estremi associati a forti impulsi direzionali.
- **Dati Sintetici:** Il modello LLM tende a generare una variabile X più "pulita" e meno rumorosa.

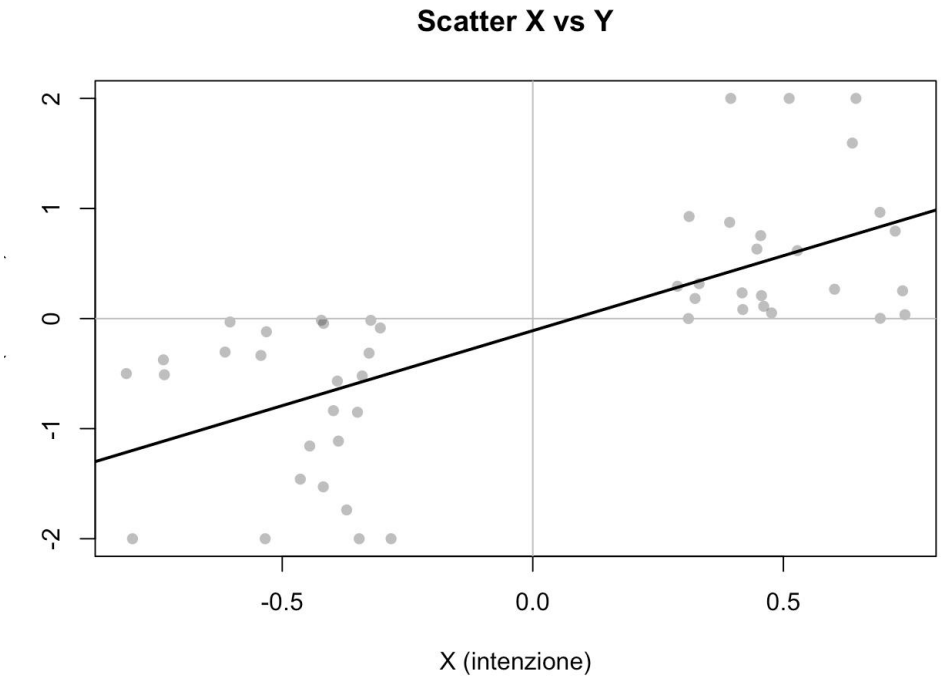


Osservando l'istogramma riportato sopra, notiamo che sebbene i vincoli geometrici OHLC siano rispettati, la distribuzione sintetica appare artificialmente ordinata. Manca spesso quella variabilità stocastica estrema e quel "disordine" sulle code che caratterizzano i mercati reali, suggerendo che l'IA tenda a mediare eccessivamente i comportamenti estremi.

8.3.2 Relazione di Dipendenza e Correlazione (X-Y)

Come osservato nello scatterplot del dataset reale, esiste una tendenza positiva tra intenzione (X) e reazione (Y), seppur accompagnata da una marcata dispersione e da fenomeni di eteroschedasticità.

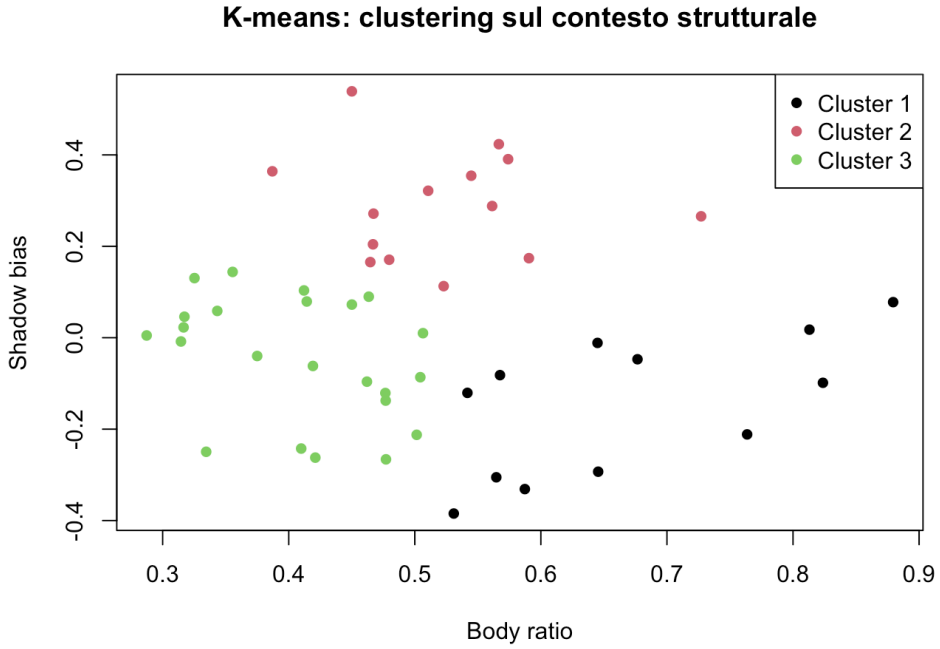
- **Analisi del LLM:** Il modello generativo tende a sovrastimare la linearità della relazione. Mentre nel mercato reale la reazione Y è influenzata da fattori esogeni rumorosi, i dati sintetici mostrano una risposta troppo coerente.



Lo scatterplot evidenzia chiaramente questo fenomeno: i punti si allineano con eccessiva precisione lungo la retta di regressione. Questa "iper-coerenza" indica che il modello simula un mercato ideale dove a ogni azione corrisponde una reazione quasi deterministica, ignorando l'imprevedibilità tipica del trading reale.

8.3.3 Coerenza del Clustering

Un aspetto positivo emerge invece dall'analisi strutturale. Applicando il modello K-means ($k = 3$) ai dati sintetici, è stato possibile identificare le medesime strutture geometriche documentate nel dataset originale.



Come visibile nel grafico dei cluster, l'IA ha generato forme ben distinguibili: candele impulsive (in un cluster), rifiuti rialzisti e ribassisti (negli altri). La netta separazione dei colori conferma che il LLM ha interiorizzato correttamente la morfologia delle candele finanziarie, replicando le "forme" dell'analisi tecnica con grande accuratezza.

8.4 Discussione: Pro e Contro dei Dati Sintetici

La validazione evidenzia una dualità netta nell'uso dei *Large Language Model* per la finanza. Sebbene siano strumenti eccellenti per generare strutture di dati coerenti dal punto di vista formale, faticano a replicare l'entropia dei mercati.

Possiamo riassumere le evidenze in due categorie distinte:

- **Punti di forza:** I dati sintetici sono **geometricamente perfetti e privi di errori tecnici**. Questo li rende ideali per il *debugging* di codice (es. verificare se uno script R calcola correttamente le medie o se un algoritmo di clustering gira senza errori) e per situazioni in cui la privacy dei dati reali è prioritaria.
- **Criticità:** I dati mancano di **realismo comportamentale**. La ridotta componente di rumore e l'assenza di anomalie strutturali non lineari li rendono pericolosi per il *backtesting* di strategie operative. Una strategia di trading testata su questi dati potrebbe mostrare performance illusorie, poiché il mercato sintetico è troppo "facile" e prevedibile rispetto alla realtà.